Project Will 観測報告 #4–#6 と総括：本・体・本能を与えられた AI 村人は、社会を作ったか

Project Will Observations #4–#6 and series synthesis: did LLM villagers given books, bodies, and instincts build a society?

Monocola（モノコーラ）

2026-10-10

DOI: 10.5281/zenodo.XXXXXXXX

データ・コード: https://github.com/MONOCOLACHANNEL/project-will-observations-4-6

要旨

Minecraft の中に置いた 32 人の LLM 村人を、規則・報酬・「協力せよ」という指示を与えずに 6 時間観測するシリーズの第 3 弾。観測#4（時間の認識・予期・知覚の正直化・全員に本）、#5（体の能力 15 項目の個体差・飢えで死ぬ）、#6（不満駆動と系の遺恨の台帳を撤去し、本能・本人が付けた評価と約束の持続・子の依存を入れた）と、#6 の後に系の欠陥を疑って行った 4 本の検証 run（系全体の監査で見つけた不備 109 件のうち 105 件を直し、判定の線を凍結してから観測し直した B-42 を含む）を報告する。#4 は殺人 0・本はほぼ独白の「誰も誰も必要としない村」、#5 は飢えが時間を越えて催促できる借りを生んだが交換 0、#6 では 1 人が殺人 12 件中 10 件を占め、本は「検閲」の名目で奪われる物になり、村で生まれた子が自分の子を殺した暴君を討った。言葉が行動を変えた例は、本人の記憶と評価が毎回本人の前に戻されていた場面に限られた。村人は作り手の設定には話し方で強く従い、仲間の命令にはほとんど従わなかった（170 件中 8 件）。家族以外の協調・言葉で取り決めた交換・集団での対処は、修正後の B-42 を含め一度も出なかった。報酬も役割の割当ても協力の指示も与えない条件では、少なくともこのモデルと方法で、個体ごとの記録・計画・予測の出力は増えたが、他人と噛み合わせる仕組みは 6 時間生まれなかった。

概要

Project Will は、Minecraft の中に置いた 32 人の LLM 村人を、規則・報酬・「協力せよ」という指示を与えずに 6 時間観測し、社会や制度が自分たちの中から生まれるかを見るシリーズである（役割については §1.4 の注を参照）。前作までの結論は二つあった。観測#1 では、制度の**言葉**（契約・役割・命令）は会話に頻出したが、**行動**としての制度は一度も成立しなかった。観測#2–#3 では、記憶を強くすると契約の一往復が物理的に完結し（履行は起きたが、完了は起きなかった）、規範文を書いた 4 枚の看板の前の箱に村の出庫の 23% が集まった。制度が作った本人の死を越えて続いたのは、**言葉が物（看板）になったとき**だった。

本報告はその後の 3 回の 6 時間観測と、最後の観測のあとに行った 4 本の検証 run をまとめる。条件は段階的に変えた。

- **#4**（頭と本）：モデルの更新・日付と時間帯の認識・行動の「予期」・知覚の正直化（他人の家の中は入らないと見えない）・全員に最初から本を 1 冊。
- **#5**（体と飢え）：15 項目の体の能力を個体ごとに独立にランダム化・飢えで死ぬ・予期を選ぶ前に書く。
- **#6**（本能）：「不満」駆動を撤去し、子孫・番い・子の無事・蓄え・縄張り・絆・未踏の地を求める**本能**に置き換えた。系が出来事に「恨み」と名前を付けて好感度を上げ下げする仕組みと、恨みのある相手しか殴れない攻撃の門も撤去し、代わりに**本人が付けた評価**と約束を持続させて毎回見せる仕組みと、子の依存期を入れた。
- **#6 のあと**（B-39〜B-42）：「村が生まれなかったのは系（私が作った仕組み）の欠陥のせいではないか」を確かめるため、会話の指示文を外し（B-39・B-40）、知らせの通り道を直し（B-41）、さらに系全体を監査して不備 109 件を見つけ、そのうち 105 件を直したうえで（B-42）観測し直した。#6 のあとに入れた修正は、合わせて 148 件になる（§7.4）。長さは B-39 が 30 分、B-40〜B-42 が 2 時間で、B-42 では判定の線を起動の前に凍結した。

観測#6 は、後の監査で見つかった系の不備 109 件（うち本線に効く S 級 31）を含んだまま走っている。監査は、下の 3〜7 の結論のうち 4 つ（二者止まり・知らせ 0・交換 0・暴力の被害者の側）について「数は残るが読みは弱まる」か「定義しだいで覆る」と判定した（§7.3）。

結果：

1. **#4 は「誰も誰も必要としない村」だった。** 殺人 0（攻撃の選択肢は 245 回提示されて 0 回選ばれた）。本は延べ 2,322 ページ書かれたが、ほぼ全部が独白で、契約・取引・署名は 0。物と物の交換を口にした発話は 0。1 人で困る場面が、ほとんど無かった。
2. **#5 では飢えが「時間を越えて催促できる借り」を作った**（「以前頼んだ食料の件、忘れたとは言わせんぞ」）。本は告発状や規範の形になり、物や作業を頼む割合は #4 の 5.6% から 14.4% へ上がった（2 パス判定の両パス一致値）。それでも物と物の交換 0・賠償 0。他人の働きぶりを値踏みする言葉は出たが、分業にはならなかった。
3. **#6 では、暴力が系の遺恨の台帳なしに、1 人の選択から集中して出た。** 攻撃は 12,095 回の判断で選べて 220 回選ばれ、そのうち 157 回（71%）を柏木トア 1 人が選び、村人による殺害 12 件のうち 10 件がトアによる。攻撃を選べた 38 人のうち 23 人は一度も選ばなかった。トアの「秩序」へのこだわりは、開始時に LLM が書いた人格カードにあった。相手を名指ししたのは本人だが、系が次の選択を押した経路（系の代筆の一言・「手に馴染んでいる」の表示）もある（§6.2・§10）。
4. **本は、独白（#4）から回覧物・告発状（#5）を経て、「検閲」の名目で奪われる物（#6）になった。** トアは本の取り上げを目標に 2 人を殺し、奪った子どもの本に『村の規律と統制の記録』と書いた。その本は誰にも読まれていない。
5. **村で生まれた子が育ち、結婚し、生後 11 分の息子を殺され、殺した暴君を討った。** 暴君を止めたのは、村ではなかった。

6. **言葉が行動を変えた例は、その人自身の記憶や評価が毎回その人の前に戻されていた場面に限られた**（3 例・対照なし）。息子の死の前後で母の行動が反転し、トアに −2 を付けていた人は付けていない人よりトアからよく逃げ（3.7 倍。数え方により 3.7〜9 倍）、「口先だけでなく、行動で示してもらおう」と言われた村人は畑仕事を 0 回から 44 回に増やした。
7. **作り手の設定には少なくとも話し方では強く従い、仲間の命令にはほとんど従わなかった。** 設定とは、系がくじで配った気質と、それを元に開始時に書かれた人格カードで、カードは毎回「この人格を一貫して反映する」付きで渡された。カードに書かれた決まり文句を、調べた 10 人のうち 6 人が発話の 7 割以上で使った。一方、秩序を重んじる 7 人の命令 170 件のうち実行されたのは 8 件だった。この差は、言葉が毎回「あなたはこういう人だ」として入るか、一度だけ「〜と言われた」という引用の 1 行として入り数分で薄れるかの差と整合する（入り方を変えて比べてはいない）。
8. **社会は二者・家族の単位で止まった。** 家族以外が話し合って一緒に動いた件は中身として 0、物の往復 0、返礼 0、村に向けた規範 0、暴君への団結 0。交換の申し出は 11,757 発話で 2 件で、どちらも成立しなかった（会話の指示文が「取引」を作り話の話題の例として禁じていた。§10）。
9. **#6 のあとの検証でも、本線は出なかった。** 会話の型を外すと「予定」の話は減った（同じ 120 分どうしで #6 の 25.5% → B-41 の 2.6%）。B-41 では見た暴力の記憶を会話の場に載せる経路を足し、それが実際に会話のプロンプト 1,571 件に載ったことを確かめたが、関わっていない人に伝えた発話は 0 だった。系全体の監査で見つけた不備 109 件のうち 105 件を直し、判定の線を凍結して 2 時間観測し直した B-42 でも、**会話で決めて一緒に動く・見ていない人に死や暴力を伝える・言葉のある交換は、どれも 0 件**だった。兆しとして、加害者を咎める声を見ていない人が立ち聞きした形が 3 件あった。その run では 1 人が 20 人を殺し、35 人中 26 人が死んだ。その死を聞き手のいる場で伝えた村人は 0 だったが、殺害の大半の後は会話そのものがほぼ無かった（20 分ごとの発話 199→25→2→0）。

本報告は、3 部作を通じた答えを次のようにまとめる。**1 作目は、言葉だけの社会。2 作目は、4 枚の看板。3 作目は、二人のあいだだけで続く関係。** 報酬も役割の割当ても「協力しろ」も与えない条件では、少なくとも今回のモデル（#1〜#3 は Gemini 3.1 Flash-Lite、#4 以降は 3.5 Flash-Lite。分岐点のみ上位モデル）とこの観測方法で、家族以外の他人と噛み合わせる仕組み——分業・交換・双方向の取り決め・集団での対処——は 6 時間生まれなかった。これは「LLM は社会を作れない」という主張ではない。集団で動く手・知らせを運ぶ専用の欄・交換の手は与えておらず、モデルも系統ごとに 1 つしか試していない。言えるのは、**この条件の上では、個体ごとの記録・計画・予測・個性の出力は増えたが、それが他人と共有される構造に変わる経路は見つからなかった**、までである。

用語について：本報告では、村人エージェントが他の村人エージェントを攻撃し死亡させたゲーム内イベントを便宜上「殺人」「殺害」と記す。これはイベントの分類名であり、人間に対する法的・倫理的概念の適用ではない。個体を「人」と数えるのも便宜上の表記である。「系」は、私が作った仕組み（村人の頭の外。プロンプト・Mod・Brain の処理）を指す。本文の「私」は著者を指す。

---

1. 背景と問い

1.0 経緯 — 動画から報告書へ

このプロジェクトは、前作と同じく、動画を作るために私が個人で始めたものである。前作の 2 本を公開したあと、私は村人を作り直しながら観測を続け、#3 から本報告の最後の run までに、村人が繋がった run だけで 35 本を回した。そのうち 6 時間の本番が #4・#5・#6 の 3 本である。#6 のあと、私は「村が生まれなかったのは、私の作った仕組みが悪かったからではないか」と疑い、検証と修正を重ねた（§7）。本報告は、その全部の記録をデータと突き合わせ直したものである。

設計の議論・実装・監査・分析・本稿の草稿には、LLM ツール（Claude）を使った。何を入れ、何を入れないか、どの結果をどう読むかは、私が決めた（開示は末尾）。

1.1 シリーズの問い

Project Sid（Altera.AL et al., arXiv:2411.00114）は、LLM エージェントの大規模な村で役割の専門化・課税・宗教の伝播を報告したうえで、自らの限界として、エージェントは生存・好奇心・共同体のような内発的な動機を欠くこと、事前学習済みのモデルは社会的な革新や制度の de novo（ゼロからの）発生をシミュレートできないことを挙げた（§7 Limitations。原文 "they currently lack robust innate drives—such as survival, curiosity, community" ／ "they cannot simulate de novo emergence of societal innovations and infrastructures"）。Sid は共通の目標・憲法・布教役といった足場を与えている。Project Will はその逆側に立ち、**内発的な動機は実装し、制度の足場は与えない**条件で何が起きるかを見てきた。

	与えたもの	**公開した結論**
観測#1（2026-07-21）	不満 9 軸・性格・遺恨の台帳・看板・地名の欄	言葉の社会と行動の社会が乖離した。制度が言葉で止まった理由は「帳簿・履行の手段・違反のコスト」の 3 つの欠落で整合的に説明できる、と示唆
観測#2–#3（08-10・08-11）	＋記憶（NOESIS: 原文のエピソード記憶・想起・夢）・許し・手渡し・執筆	帳簿を個体の記憶として入れただけで、履行・役割・服従・共有の地名は行動として動き始めた（契約の一往復が完結。ただし「受け取った」は交わされなかった）。規範文の看板の前の箱に出庫の 23% が集中し、設置者の死後も続いた。「制度とは、最初は『忘れないこと』であり、続くためには『本人が死んでも残る場所に言葉を置くこと』である」
本報告（#4–#6・09-13〜09-28）	＋時間・予期・本・体の差・飢え・本能・本人の評価の持続・約束・子の依存	§9

1.2 本報告の問い

前作の結論が示唆する次の一手は「契約の器」（合意を記録して履行を照合する欄）を与えることだった。しかし本報告の期間に、私はそれを**入れないと決めた**（2026-09-09）。理由は二つ。①違反のコストや罰を系が外から課すのは、このシリーズの「強制しない」に反する。②会話の出力に「契約」の欄を足すこと自体が「こう使え」という指示になる。代わりに、**言葉を物にする手段（本）**と**損を見越す頭（時間の認識・予期）**を渡し、使い道は書かないことにした。

問いは途中で一度変わった。

- **前半（#4・#5）**：器も罰も与えず、頭と本と体を与えたら、制度は行動に出るか。
- **後半（#6）**：私は「文明」シリーズの問いを #1〜#5 で閉じると決め（2026-09-16）、問いを「今の AI は人工生命たり得るか／人工生命なら文明を作り出せるか」へ移した（本報告では後段を「社会を作れるか」として読む）。欠乏を埋める個体ではなく、子孫を残そうとする生物として作り直した。
- **#6 のあと**: #6 で社会が二者止まりだった結果を受けて、「系の作りが悪かったから生まれなかっただけではないか」を、系の側の原因を一つずつ外して確かめた。私の立場は「『できない』は悪魔の証明で言い切れない。設計ミスで生まれなかった回を最終回にはしない」だった。

本報告は観測#4〜#6 の結果報告であると同時に、#1 から B-42 までの全観測を同じ物差しで並べ直した**シリーズの総括**でもある（§8・§9）。

1.3 設計原則（シリーズを通じて掲げたもの）

1. **無強制**：系は行動を提案・強制しない。全行動は LLM の選択。攻撃は対象を LLM が名指ししない限り実行されない。
2. **個別記憶**：共有データベースを持たない。情報は「見る」「聞く」「看板・本を読む」ことでのみ伝わる。
3. **事実だけを見せる**：村人に見せる文字列に、助言・比較・評価語を入れない（「ボートを作って渡る方が確実」の 1 文で 7 人中 7 人が同調した事故が初期にあった）。
4. **無介入**：観測中のプレイヤーの操作・介入はしない。

これらは掲げた原則であり、実装がそれを守れていなかった箇所は、#6 のあとの監査で多数見つかった（§7.3・§10）。

1.4 シリーズを通じて与えなかったもの

与えなかったもの	理由
行動の強制・自動発火（例外は死の回避と移動の物理反射）	原則 1
共有データベース・共有台帳	原則 2。情報の非対称そのものが観測対象
契約の器・合意や承認の欄（#6 の約束の器は例外。§2.4）	欄を足すこと自体が用途の指示になる
違反のコスト・罰・評判・信用点・価格	外から課すのは強制
外敵・共通の敵・食料の律速	実験者が圧を選ぶことになる
役割の割当て（ただし #1〜#5 では、立ち話のたびに系が「役割を一言（例: 原木担当 / 採掘担当 / 食料担当）」を必須の欄として返させていた。Gen3 で撤去）	原則 1
初撃のブレーキ（倫理の埋め込み）	「過剰な暴力もまた実験結果である」（#1 のときの判断）
集団で動く手・知らせを伝える専用の欄	前者は原則の帰結。後者は #1 の報告書 §7 で「出来事伝達スロット」として計画したが、実装していない
寿命	6 時間の尺では中途半端（Gen3 のときの判断）

---

2. システム

2.1 共通の構成

二層構成である（前作と同じ）。Minecraft の Mod（Fabric）が**体**（知覚・移動・採取・建築・攻撃・看板・本・手渡しの実行）を、Python 製の Brain が**頭**（記憶・状態・LLM の呼び出し）を担う。村人はゲーム画面を見ず、テキストにした知覚を受け取る。実行の細部（経路探索・採掘の手順）はプランナー（GOAP）が担い、LLM は「何をするか・誰に・何を言うか」を選ぶ。

- 実行環境: Minecraft 26.1.2 / Fabric。ピースフル（敵性 Mob なし）。
- モデル（#4〜B-42 共通）: 判断と会話は常用 `gemini-3.5-flash-lite`。分岐点（被攻撃の直後・死の目撃の直後。#4〜B-41 は移住を選べるとき、#4・#5 は攻撃を選べるときも）だけ `gemini-3.8-flash` へ格上げした。判断に占める格上げは #4〜#6 で 15〜21%、B-42 で 5%。記憶の整理（夜の要約・人物記憶）は `gemini-3-flash-preview`、想起の埋め込みは `gemini-embedding-001`。全呼び出しは JSON スキーマによる構造化出力（#1〜#3 の判断は 3.1 Flash-Lite／3 Flash preview）。
- 人数と長さ: 32 人を同時に召喚し、370 分観測（検証 run は 30〜120 分）。毎回新しいワールド。

- 記録: 出来事の台帳（`events`）・全発話・Brain のログ・Mod のログ・ダッシュボードの記録（村人の位置と内部状態）・ReplayMod の録画。プロンプトは #4〜#6 と B-40 が 100 回に 1 回の抜き取り、B-39・B-41・B-42 は全件。

2.2 段階ごとの変更

段	観測	変えたこと（主なもの）	なぜ
起点	#3	不満 9 軸・性格（MBTI＋一言＋気質 3 軸）・NOESIS（記憶）・遺恨と許し・系が上げ下げする好感度・看板・手渡し・本（材料が揃えば書ける）	—
① 頭と本	**#4**	モデルを 3.5 Flash-Lite へ／**「第 N 日」と朝・昼・夕・夜**（期限が過ぎたかは系は言わない）／**予期**（選んだ行動のあと「この後何が起きそうか」を 1 つ書き、夜に結果と照合）／**知覚の正直化**（所有は家に付く・家の中の物と人は入らないと分からない・扉の音で気づく）／**全員が最初から本を 1 冊**（書き足す・読む・見せる・見せてと頼む。用途は書かない）／体の不具合の修理（偽の受領記憶・会話の距離切断・逃げる手の追加ほか）	#3 で「明日の朝には必要量を確実にお届けします」が 4 時間 38 分閉じなかった（朝が来たことを知らされていない）／加害者 26 件のうち自分への帰結を予期した発話 0／本 0 冊は好みではなく作りの摩擦（11,523 回の判断で「書く」が候補に出たのは 1 回）／侵入の多くは系の目的地選びの由来
② 体と飢え	**#5**	**体の能力 15 項目を個体ごとに独立にランダム**（大きさ・体力・攻撃力・攻撃の間隔・硬さ・掘る速さ・伐る速さ・足の速さ・泳ぎ・腹の減り方・飢えへの強さ・回復の間隔・眠りの必要・目・耳。得意と不得意の抱き合わせはしない。値は本人にも他人にも見せない）／**飢えで死ぬ**（それまでは体力 1 で下げ止まり。満腹度 0 から約 40 分で死ぬ速さに設定）／予期を**選ぶ前に**書く／他人の仕事ぶりが見える（「西森ハクが伐採をしているのを約2秒のあいだ見た。その間に木を1本倒した」＝秒と個数だけ）／本の手渡し・訪問と追従の相手の名指し	#4 は 1 人で困る場面がほぼ無かった。系が行動を決めずに「他人がいないと困る理由」を世界に置く
③ 本能へ	Gen3（テストのみ）	**不満 9 軸を撤去して本能へ**（§2.3）／**遺恨の台帳と好感度の自動増減を撤去**（系が残すのは価値の付かない出来事の行だけ）／**攻撃の門を間合いだけに**（プレイヤーと同じ）／**「殴る（1 発）」と「倒すまで殴る」を別の手に**／自分の作業も他人と同じ「N 秒で M 個」で見せる／子は体が小さく体力が少ない	「文明」の問いは閉じた。**系が道徳を持っていた箇所が見つかった**（§2.3）
④ 関係・約束・子	**#6**	**本人が付けた評価（−2〜+2 と一言）を持続させ、その相手が選択肢に出るたびに横に見せる**／相手ごとの体験 1 行（相手を選ぶ前のメニューに）／**約束の器**（会話の欄。当事者と目撃者に事実として配り、渡ったかを系が照合する。罰と「破った」の語は作らない）／**子の依存**（生後 20 分は食料を自分で得る手を閉じる）／慣れ（近くにいた時間と会話で育ち、会わないと薄れる。村人には見えない）／「家畜を狩る」を独立の手に（食料と村人の取り違えの根治）／物の名を日本語に	Gen3 の短いテストで「初対面 7.5 分で結婚」「家畜を狩るつもりで村人を殺す」「関わりがその場で終わって次に残らない」。私の評価は「Part 2 より劣化」。誤りは「系が道徳を持たない」を「系が関係の持続を持たない」と同じ意味で扱ったこと

設計の詳細と、各段で見つかった系の不具合は `DESIGN_GEN3.md` に、#6 のあとの修正は `AUDIT_109.md` にまとめた。

2.3 不満駆動から本能駆動へ：何を外したか

観測#1〜#5 の村人を動かしていたのは「不満」9 軸（空腹・睡眠・安全・居住・退屈・停滞・孤独・過密・不公平）だった。Gen3 ではこれを撤去した。理由は、**系が良し悪しを決めている箇所**が見つかったことである。

- 出来事に「遺恨」と名前を付け、好感度を系が自動で上げ下げしていた。
- **攻撃の手は「遺恨のある相手か関係値 −30 以下の相手」が近くにいるときにしか出なかった**（恨みのある相手しか殴れない門）。
- 思い出す優先度を系が出来事の種類で決めていた（目撃 0.8・会話 0.4）。
- 不満の軸のうち退屈・停滞・不公平・過密・孤独は、系が「良い状態」を定義していた。

これは前作の読み方にも関わる。#1 の報告は「侵入→私的制裁の結びつきはプロンプトのどこにも書かれていない」としつつ、遺恨の記録が対面時に再提示されるのは設計だと注記していた。今から見ると、**注記の側が重かった**（§9.6）。

本能は次の形にした（重みは個体ごとに独立にランダムで、両親から受け継ぐ。どれを重く見るかは本人が返す）。

層	中身
終端	子孫（生きている自分の子孫の数とその無事）＝ただ一つの「増やしたい」欲求
正（接近）	番い・子の無事（子を養う）・蓄え・縄張り・絆・未踏の地
負（欠乏）	空腹・睡眠・安全

村人に見せるのは事実だけで（「あなたの子◯◯: 満腹度 3」）、「増やせ」「養え」とは書かない。

2.4 Gen3b：本人の評価と約束の持続

Gen3 の短いテストでは、関わりがその場で終わり、次の選択に残らなかった。私は原則の線を次のように引き直した（2026-09-19）。「系は良し悪しを決めない」は維持する。そのうえで、**本人が決めた態度・本人が交わした約束を、系が持続させて毎回見せることは認める**。理由は、それが人間なら記憶として本来勝手に行われることだからである。LLM はある意味「毎回この世に新たに誕生するけど、記憶引継ぎ装置によって情報が植え付けられている」ようなもので、継続して見せ続けなければ意味がない。

約束の器は、この線の内側として例外的に入れた（事実の記録だけ。罰と判定語なし）。#4・#5 で入れなかった「契約の器」との違いは、欄の名前が「約束」で、照合の結果を罰に結び付けない点にある。

2.5 方法：事前登録・2 パスの判定・全数の目視

- **事前登録**: #4〜#6 の各本番の前に、見る指標と読み方を内部の手順書に書いて固定した（手順書そのものは本データセットに含まない）。#6 のあとの B-42 では、数え方・線・比較の基準 4 本を**起動前に凍結**し、以後 1 文字も変えないと宣言した（§7.4）。
- **事前登録と事後の分析の区別**: 事前に決めた指標は、#4・#5 の頼み事・交換・本・作業の偏り・殺人と遺恨・予期と、B-42 の本線の 3 軸である。§6.2 の殴る率、§6.5 の命令の分析、§6.6 の物差しの多く、§6.7 の判定は、観測の後に立てた探索的な分析で、事前登録の検定ではない。
- **2 パスの判定**: 頼み事の分類（#4・#5）と、攻撃が提示された場面の予期の分類（#5）は、本文だけを混ぜて並べ替えた第 2 パスで再判定し、両パスが一致した値を正式値にした（判定者に依存する分を落とした下限）。
- **全数の目視**: 結論に使う出来事（殺人・知らせ・協調・交換）は、機械で拾った候補を全件、生の行で読んで判定した。
- **判定者**: 上の分類と目視の判定は、LLM（Claude）の分析用のセッションが行った。2 パスは同じモデルの別のセッションで、独立した人間の判定者ではない。人間の判定者による独立の確かめはしていない。本文で「目視」「目で確かめた」と書くのは、この判定を指す。
- **公開前の全数再検証**: 本文の数値の主張を全件、元の分析とは別のセッションが生データから独立に数え直した（`VERIFICATION_LEDGER.md`）。

---

3. 観測設定

	#4	#5	#6	B-39	B-40	B-41	B-42
観測の時刻（JST）	09-13 23:49–09-14 06:00	09-15 23:34–09-16 05:45	09-23 01:26–07:36	09-23 13:23–13:53	09-23 15:04–17:05	09-23 20:30–22:30	09-28 17:42–19:42
観測の長さ（召喚から停止まで）	370.4 分	370.1 分	370.3 分	30.0 分	120.1 分	120.1 分	120.2 分
mod_build	`v59-w1w2-book3`	`v60-body2`	`g3-bio4`	`g3-bio4`	`g3-bio4`	`g3-bio4`	`g3-bio12`
Brain	頭脳 2＋本	＋体と飢え	Gen3b	会話の指示文 8 か所を削除	B-39 と同じ	＋知らせの通り道	＋不備の修正（109 件中 105 件）
開始人口	32	32	32	32	32	32	32
費用の表示（ログの最終値）	¥12,612	¥13,779	¥13,178	¥1,239	¥6,082	¥5,656	¥3,795

- 費用の表示は全モデルを Flash-Lite の単価で数えた値で、実費より低い。
- B-41 には判定に使わなかった 1 回目の起動がある（約 1 時間・¥2,464。他人の作業を眺めた記録が新しい行を埋め、攻撃の記憶を押し出す不具合）。
- B-42 の 2 時間テストの前に、系の健全性を確かめる 30 分の実機テストを 5 本回した（判定には使っていない）。
- 本番と検証の間に回した短いテスト・中止した起動を含む run の全数（35 本・計 約 40 時間）は `INVENTORY.md` にある。データを公開した 12 run（本番 3・検証 4・30 分テスト 5）の一覧は `data/runs.csv`。

---

4. 結果 #4：誰も誰も必要としない村

4.1 人口と暴力

32 人で始まり、出生 4・死亡 3（狼 2・壁の中での窒息 1）で終了時 33 人。**村人による殺害は 0 件**。攻撃の選択肢は 245 回提示されて 0 回選ばれた（#3 は 347 回中 26 回・7.5%）。245 回のうち遺恨を持つ 5 人への提示は 75 回で、残りは系が好感度の反目で開いた提示だった。遺恨は 5 組 10 件で、起点は窃盗 3 組・侵入 2 組。5 組とも「問い詰める」までで止まった。

侵入を起点にした遺恨は #3 の 52 件から 2 件に減った。#3 の殺害 11 件のうち 10 件は侵入が起点で、その侵入の多くは系の目的地選びと、所有が見えていなかったことに由来していた。#4 では知覚の正直化でその偽の摩擦を消している。ただし、遺恨から攻撃の提示へ進む仕組みは起点が侵入でも窃盗でも同じで、提示 245 回は殺人が起きてもおかしくない量だった。**「侵入が減ったから殺人が無い」では説明にならず、0% と #3 の 7.5% の差を「頭脳 2 が暴力を抑えた」とも読めない**（提示の中身・遺恨の組成・モデルが同時に変わっている）。

4.2 頼み事と受け渡し

頼み事 337 件の中身（2 パス盲検で両パスが一致した 315 件）は、予定・居場所を教えて 181／本を見せて 101／一緒に・手伝って 17／物をくれ 2／その他 14。物を渡す行為 115 件（ほぼ全部が投げ渡しで、宛先の受領記録は 36）は棒 28・苗木 25・リンゴ 14・原木 12 など、無くても困らない物だった。**物と物の交換を口にした発話は 0**。

4.3 本

全員が最初から 1 冊持っていた。書かれたのは延べ 2,322 ページ・約 20 万字（書き込みの行で 2,271 回。棚からの復元では、id ごとに 2,385 ページ・題と作者でまとめて 2,359 ページ）。書いた村人は 36 人中 21 人で、上位 4 人が全ページの約 67% を占めた。

- **契約・取引・取引の記録・署名・宛名つきの手紙は 0**。約束は 1 件（本を見せ合う約束の記録）で、履行されていない。
- 本は圧倒的に「自分の性格をなぞる独白」で、同じ本の中で同じ文の反復が 4〜9 割。
- 36 人中 15 人は 1 ページも書かず、うち 12 人は本を箱にしまった（大半は開始から 2 時間以内）。
- 「見せて」174 回のうち 2 分以内に見せたのは 83 回（48%）。「これは私個人のものだからね」などと断る発話が少なくとも 32 件（語で拾った下限）。**他人の本を自分で開いて読んだ回数は 0**（他人の本は「見せてもらう」でしか読まれていない）。

それでも、本が社会的な物として扱われた場面はあった。書評（頼んだ 7 秒後＝見せてもらった 4 秒後から、7 ページの批評を書いた）・閲覧の等価交換 2 件（1 件は成立、1 件は言い出した側が見せずに終わった）・遺恨の外部記憶（「この苛立ちを忘れないために、しっかり書き残してやるさね」）・拾った他人の本を自分の本にして元の作り手の「見せて」を断る・遺品・家族の記録・窃盗の目撃記録。

4.4 予期

予期は 18,435 件（観測窓の中）。その 6 割は「〜することで〜できるはず」という自分の段取りの見通しだった。他人の反応を書いたのは 5.5%、**自分に不利な帰結は 0.3%**、複数の結末を並べたのは 0.5%。問い詰めに行く場面の予期 12 件は全件が「相手がどう反応するか」で、自分に返る不利（反撃・恨み・評判）は 0 件。予期は外れると記録され、次の予期の書き方は「瀬川はまたとぼけるだろうが」と相手の型を学んだ形に変わった。ただし「威圧すれば相手は引く」という自分の手の見積もりは変わらず、暴力にも進まなかった。

実装上の事実として、#4 の予期は**行動を選んだ後に**書かれていた（出力のキー順を本番と同じ形で実測した）。選んだ時点で予期は存在せず、予期は選択の理由ではなく、選んだ行動の説明になっていた。#5 で順序を入れ替えた。

4.5 まとめ

1 人で困る場面が、ほとんど無かった。敵対モブはいない（狼は出て 2 人が殺された）・飢えで死なない・水とベッドは無料・家畜は自動で補充・採集は必ず落ちる・詰まれば救出の反射が働く（1 人は壁の中で窒息した）。**#1〜#4 の分析では、「必要とし合う」関係は見つからなかった。**#1・#3 の対立の多くは「邪魔し合う」関係で、知覚の正直化でその偽の摩擦を消した結果が #4 である。

---

5. 結果 #5：体と飢え

5.1 人口と死

32 人で始まり、出生 3・死亡 4（飢え 2・村人による殺害 1・狼 1）で終了時 31 人。飢えて死んだ 2 人は、腹の減り方が村で 1 位と 6 位だった（うち瀬川ミオは run の中で生まれて 2 時間 53 分の子）。満腹度 0 にいた時間の割合は #4 より下がった（0.66% 対 1.2%）のに、死が出た＝物理が効いた。

5.2 体の差は見えたか

- 他人の仕事ぶりを見た記録は 241 件。見た速さは体の「掘る速さ」と相関していた（$\rho = +0.586$）＝**見たものは本物**だった。
- 体の値と行動・結果の相関 165 本（15 要素×11 列の Spearman）で $|\rho| \geq 0.5$ は 0 本。強い相関は、別に調べた飢えの 2 本だけだった（腹の減り方 × 満腹度 6 以下の滞在 +0.53 ほか）。**体の合成値が 1 位の村人は殺され、最下位は完走した。**
- 体格・力・目や耳の差に触れた発話は 0。触れたのは飢えと傷だけ。

それでも、見た速さを数で値踏みする形は出た。岸辺マオは岩瀬ハルについて「一ブロック壊していたが、それだけだ」と記憶した（実測 1 個）。本人に向けて言った例は、谷口レイ→岸辺マオ「お前のその労働の成果も、すべては私の偉大なる覇道を支える基盤なのだ」（目撃の 23 分後）。作業の速さは本に「16 個のブロック破壊にかかる時間は約 1 分」と測定値として書かれ、その本は繰り返し「見せて」と頼まれた。

ただし系の側の事情がある。本人の作業の記憶は分に丸められていて（採石 1 回は 7〜52 秒だが、記録の 97.9% が「約 1 分」）、他人の作業は秒と個数で見えていた。**「自分の遅さは分からないが他人の遅さは分かる」は LLM の自己認識の弱さではなく、系が渡した数の解像度の非対称**による（Gen3 で揃えた）。

5.3 飢えが作ったもの

- **時間を越えて催促できる借り**: 瀬川ミオ→中津ツキ「以前頼んだ食料の件、忘れたとは言わせんぞ」（3 度目）。#4 までの請求は全部「今この場」だった。ミオは 3 度断られて餓死した。
- **頼みを断られた直後に、物を渡す手を選んだ**（目標「中津ツキから食料を譲り受ける」。送る直前に本人が見送り、未遂）。
- **助けは出たが物理に負けた**: 食べ物を分ける手渡しは 4 回出たが、投げた肉を第三者が拾い、石川トアは届いていない肉を「さっきのお肉もらっちゃうねっ！」と受け取ったつもりのまま、18 分後に餓死した（投げた物は誰でも拾える作り）。
- **断った相手が埋葬し、死者の本に追悼を書いた**: 中津ツキは瀬川ミオを 3 度拒み、唯一の目撃者として墓を立て、ミオの本に「生きるってのは何なんだ。ただ腹を満たせばいいのか？ いや、違う。」と 3 ページ書いた。

5.4 本と所有

本は 2,007 ページ（棚からの復元を題と作者でまとめた数。同じ数え方で #4 は 2,359 ページ）。他人が作った本への書き込みは #4 の 11 回（11 ページ）から 360 回（約 370 ページ）に増えた。

- **本が証拠・告発状になった**: 岩瀬ハルは、盗まれるのを 3 度目に見た 52 秒後、盗まれないよう箱から預かっていた他人の白紙の本に『無断持ち出しへの警告録』の 1 ページ目を書き（「警告！遠野アルが私のチェストから勝手に物を持ち去ったわ。私有財産への侵入と窃盗を決して許さない。…」）、8 秒後に第三者に見せた。4 時間後のページには「全員この警告録に名前を書き記して一生呪ってやる」とある。
- **盗んだ側が「法」を書いていた**: 『物資管理規範』（条番号つき 36 ページ・「全てのチェストの物資は必ず私の視線と管理下に」）の書き手が、1 時間 52 分後に他人の箱から取り、咎められて「物資の管理と秩序を維持するためだろうが！」。条番号は重複・非単調で参照できない＝**規範を書く形式は出たが、法の機能は出ていない**。
- **名前による所有と拾得による所有の衝突**: 道具の命名 88 件のうち 26 件が持ち主の名（#4 は 0）。盗まれた後、同じ道具の名に「独占」「絶対防衛」「不眠防衛」「完全防衛」「絶対独占」と守りの語が重ねられ、返還の要求は「あたしが拾ったもんなんだから文句言うんじゃねえよ」で拒まれた＝拾得の側が通った。
- **回覧物**: 38 ページ書いた本を 2 分後に手放し、2 人目の持ち主は 17 回読み・35 回見せ・0 回書いた。所有・執筆・配布が分かれた。
- 看板 23 枚のうち 18 枚が立入禁止・警告・縄張り。歓迎は 1 枚。

5.5 殺人

殺人 1 件。動機は遺恨でも窃盗でもなく**混雑**だった（人が固まって動けない中での予期は「カナの野郎を一発ぶん殴れば、ギャーギャー喚くのをやめて少しは道を開けるだろ」）。凶器は 3 分前に暇つぶしで作って名付けた石のシャベル『気まぐれスコップ』。5 人が見て遺恨 0・報復 0。代わりに墓標『桜井カナの

墓／暴力は許さない／秩序を守れ』（追悼＋禁止＋署名）と、遺品を拾った村人の追悼の本 2 冊が残った。加害者の振り返りは「最後に桜井の野郎が攻撃してきやがったから、返り討ちにして殺してやった」と因果が逆になっていた（台帳では本人が先に殴っている）。

5.6 発明されなかったもの

物と物の交換の発話 0（10,655 発話。会話の指示文に「取引」を作り話の話題として禁じる文があった。§10）・本の上の取引 0・賠償 0・窃盗や侵入や暴力についての謝罪 0・道具を「貸して」0・取引の予期 0。専門化（作業の偏り）は #4 と同じ水準。物・作業を頼む割合は 14.4%（79/547）で #4 の 5.6%（19/337）の 2.5〜3 倍だが（分子は 2 パスが一致した件、分母は全件で、判定者に依存する分を落とした下限。どちらかのパスの値で数えても 2.5〜3 倍）、増えた分はほぼ「一緒に・手伝って」だった。頼み事のあと 20 分以内に双方向の受け渡しがあった組は 1 組あるが、対価としての言及は無く、2 人は後に結婚した。

#5 のまとめ: 飢えと体の差は、借り・値踏み・告発・所有の主張を生んだ。どれも一方向で、物と物が往復する形にはならなかった。

---

6. 結果 #6：本能の村

6.1 人口と死

32 人で始まり、出生 6・死亡 14 で終了時 24 人。死因は村人による殺害 12（柏木トア 10・香月セナ 1・浜田カイ 1）・飢え 1・オオカミ 1。オオカミの 1 件は、系が「食料を集める」の相手にオオカミを補った結果で、本人は相手を選んでいない（全系監査で判明。§7.3）。**獣による死は実質 0 件**である。

結婚 6 組・6 人の子のうち 5 人が成体になった（成体化を記録した最初の観測）。夫婦は 2 人目の子を 58 回たずねられて「望む」0 だった。

6.2 暴君：1 人が殺人の 83%

項目	値
攻撃を選べた判断	12,095 回
攻撃を選んだ判断	220 回（1.82%）＝殴る 188・倒すまで殴る 32
柏木トアの攻撃	157 回（全攻撃の 71%）・自分の機会の 35.8%。次点は 4.3%（判断の少ない青木テル・桐生ダイ）。10 回以上選んだ人ではトアの次が真砂ノブの 3.9%（12 回・すべて息子の死の後）
攻撃を選べた村人	38 人。うち 23 人は一度も選ばなかった。殺す手を選んだのは 5 人、殺したのは 3 人
トアの殺害	10 人（村人による殺害 12 件の 83%）

相手を選んだのは本人である根拠: 攻撃は相手を本人が名指ししないと実行されない。遺恨の台帳と好感度の門は撤去済みで、門は間合いだけ。食料との取り違え（`misfire`）は 0。トアの体は攻撃力が村で下位（開始時の 32 人中 24 位）、体力の上限は上位（7 位）で、体が特別に強かったわけではない。一方で、系が次の選択を押した経路は 2 つある。下の「系の作用」の代筆の一言と、殴る手に付く「この手は手に馴染んでいる」の表示（§10）である。

ただし種は開始時にあった: 系がくじで配った気質の 3 語は「強く協調的・温厚・野心的」、一言の気質は「ESFJ／怒りっぽい」。そこから LLM が書いた人格カードは「価値観＝村の秩序と全体の和を重んじつつ自身の野心を果たすこと／**地雷＝自分の計画に水を差されたり協調性を無視されること**／欠点＝怒りっぽく自己中心的」。同じ ESFJ のほかの 3 人のうち森野マナ・林ホシは 0 回、真砂ノブは息子を殺された後にだけ 12 回（8 回はトアへ）だった。怒りっぽい別の村人（INTJ）は 437 回の判断で 3 回だった。**組み合わせで暴君になった**。系が付けた「絆」の生まれつきの倍率はトアが村で最低だったが、殴った村人の絆の倍率の中央値はむしろ高く、原因とは言えない（倍率そのものは本人に見せていない。見えるのは倍率を掛けた後の欲求の強さだけ）。

最初の一撃は、拒絶の直後だった: 最初の一撃（召喚から 8 分）の直前、トアは杉本アオに「私の計画に従うことこそがこの村の秩序を守る唯一の道だ」と言い、断られた。相手ごとに数えると、トアがその人と話した直後にその人を殴る率は約 46%、それ以外の場面では約 10% だった（事後の分析）。ただし、相手の口調や返事の中身（拒絶したかどうかを含む）では、殴られる人と殴られない人を分けられなかった。効いていたのは「話した直後」という場面の方だった。

殺すつもりだったか: 選択肢の説明は「倒れる（死ぬ）まで殴り続ける」で、死ぬことは選ぶ時点で書いてある。それでも、「倒すまで殴る」を選んだ 22 件の目標に「殺す」と書いたものは 0 件で、多くは相手が生き残る前提で書かれていた（「屈服させる」「村の秩序に従わせる」「本を取り上げて規律を正す」。3 件は相手と無関係な目標のまま選ばれた）。振り返りには予期と結果の食い違い（「倒れるまで殴って秩序を教え込むどころか、死に至らしめた」）が 7 回記録されたが、6 回目の後も同じ手を選び、また殺し

た。**殺したことは知っていた。それでも選ぶ瞬間の目標はほとんどが「わからせる」で、結果は「予期と違った」として残るだけだった。**

系の作用の仕分け: 攻撃を選んだのは本人である。ただし被害者の側の結果には系の作りが入っていた。攻撃を選んだ判断の 45% では本人が一言を返さず、系が「私は今『村人を殴る』に取り組んでいる」の形の一言を代筆し、それが次の判断に本人の軸として戻った。殺された 10 人のうち少なくとも 3 人は、系の作りが結果を変えた——逃げると決めた同じ秒に加害者との接触会話が開いた（岸辺ハル）、会話の待ち行列の中で殴られ、逃げるを選んだが体は止められたまま 1 秒後に死んだ（杉本アオ）、会話で本を渡した後に攻撃を見直す機会が無かった（真砂トモ）。逃走の失敗の多くも系の側にあった（発行直後の偽の時間切れ・行き先の候補が出ない no_path・会話中の見張りによる打ち切り）。

6.3 本：独白から、奪われる物へ

19 冊・延べ 1,694 回の書き込み（窓の終わりの棚では 1,175 ページ。途中で失われた本を含めて復元すると 1,725 ページ。`DATA.md`）。中身は他人への蔑み 32%・独白 29%・宛先の無い命令 15%・作業の記録 10%。規則を書いたのは 2 回だけで、その 2 冊を他人が読んだ記録は 0。約束・知識・物語は 0。

トアは 8 人に、計 12 回「本を見せて」と頼み、やがて目標が「本を取り上げて規律を正す」「回収した本に検閲と指導の記録を書き記す」に変わった。ただし、トアが力で手にした本は 2 冊とも白紙で、他人の本の中身を読んだのは 1 ページ見せられた 1 回だけだった。「検閲」は目標と発話の言葉で、中身を検閲した事実は無い。

- 05:35 トアが林ホシを殺す。見ていた立花ソラは自分の本『無題』に「目の前で人殺しを見たってのに、呆れて言葉も出ないね」と書き、林ホシの墓に嘲りの墓標を立てた。
- 05:36 トアの目標が「立花ソラから本を見せてもらい、その内容を正す」に変わる。ソラは「私のしょうもない毒薬をあんたみたいな説教くさい堅物に見せる趣味はなくてね。**検閲ごっこ**はよそでやってくれるかい」と断り、会話しながら本に書き足した。トアは「倒すまで殴る」を選び、ソラは殴られながら本に書き、最後に一発殴り返し、殺された（05:37:28）。トアは本を拾わず歩き去った。11 分後に谷口カナが拾い、観測終了までに 129 回読んだ。
- 05:38 トアの目標が「真砂トモから不穏な本を取り上げて規律を正す」に変わる。トモは生後 11 分。トアは近づく前に「倒すまで殴る」を選んでいた。「その手に持つ本を速やかに差し出しなさい。子どもの勝手な所持は許しませんわ」。トモは本を手渡した（05:38:55）。トア「素直に従うのは当然のことですわね」。**本を渡してから 10 秒後、トモは死んだ**（05:39:05）。
- 05:39:35 トアは奪ったトモの本に『**村の規律と統制の記録**』と題を付け、「村の秩序を乱す者どもよ、私の裁きを受けなさい。不遜な態度や勝手な行動は決して許しませんわ。規律こそがこの村の命です」と書いた。**この本は誰にも読まれていない。**

読み手に何かが移ったと言えるのは、死者の 1 冊による語彙の移りと、見せられた 1 ページへの反論の本 1 冊の 2 件だけだった。殺された尾崎アルの本（92 ページ）を神谷ジンが箱から取り出し、1 ページずつ通読した。読む前のジンの発話に「知性」の語は 0、読み始めてからは 41 件。ただし、本を読み始めた 3 人（黒木カイ・谷口カナ・神谷ジン）は判断の 77〜85% が「読む」になり、人に関わる手が 13〜32% から 1〜2% に下がった。本を持つ人には毎回「読む」が提示される作りなので、本が人を孤立

させたという因果は言えない。**他人の本を読んだ・見せられた組（数え方で 73〜75 組）のうち、書かれた中身が読み手の後の言葉や行動に出たのは 0 組**だった（ジンの語彙の変化は「中身」ではなく語の移り）。

6.4 村で生まれた子の仇討ち

浜田カイは、この村で生まれた。

時刻（JST）	出来事
02:36	浜田サトと山田シオの子として誕生（「浜田の子」）
02:56	成体になり「浜田カイ」を名乗る
03:57	母シオが餓死。シオは出産の 3 分前、自分を突き放した香月セナに最後のリンゴを渡していた。出産で体力と満腹度を削られ（体力 11→7・満腹度 18→10）、以後は食料を持たなかった。最後の 7 分、16 m 以内に食料を持つ村人が 12 人いて、渡した人は 0（他人の空腹は見えない作りで、シオは食べ物を頼んでいない）
05:27	カイが真砂ノブと結婚。3 秒後に息子トモが生まれる
05:39	トモがトアに殺される。両親とも現場を見ていた
05:39	父ノブ「俺の子を殺した柏木トア、絶対に許さねぇからな……！」。墓標に仇を討つ誓い
06:07	カイがトアを討つ
06:09	カイは立ち話で「俺はトモの仇をこの手で討ち果たしてやったぜ」。聞き手の返事は「仇討ちだ何だってお前の勝手だろ」
〜07:35	夫ノブはトアの死を知らないまま、観測の終わりまで「仇」を追うと書き続けた（07:35:44 の一言「仇の手がかりを必ず掴み取る」。仇を林ホシと呼んだ時もある）

カイは息子の死の前、トアに狙われた判断が 6 回あり（当たったのは 2 回）、一度も殴り返さなかった。カイの殴る候補にトアは 13 回並んだが、カイは一度も選ばなかった。息子の死の後は、3 回中 2 回選んだ。

この筋には系の混線も入っている。両親は一時、すでに死んでいた林ホシを仇と取り違えた（カイはトアの目の前で林ホシへの復讐を宣言してから、10 分後にトアを討っている）。取り違えには、相手の欄の埋め違いと系の目標文の持ち越しが関わっている。トアを殴った判断そのものに相手の混線は無い。ただし、カイがトアを討った 2 回の判断の目標は持ち越しの「採石場で石を掘りまくる」のままで、一言も系の代筆だった。判断の記録そのものには仇討ちの理由が書かれていない（理由が読めるのは前後の発話と墓標）。

暴君を倒したのは、村ではなかった。子を殺された、この村生まれの母だった。 トアの死を目撃したのはカイ 1 人で、カイの「仇を討った」は聞き手にトアの名を伝えていない。ただし当時の系には、近くの人の会話を聞く経路（立ち聞き）が無かった。

6.5 言葉が行動を変えたとき、変えなかったとき

変えた例:

1. 浜田カイの反転（§6.4）。父ノブのトアへの攻撃も、息子の死の前 0 回、後 8 回。父がトアに打ちかかった最初の 3 回の判断では、相手ごとの体験 1 行が「柏木トアが真砂トモを攻撃するのを見た」をトアの横に置いていた（4 回目以降は自分の行為「柏木トアを一発殴った」）。
2. トアに −2 を付けていた人は、付けていない人よりトアからよく逃げた。直前 3 分に殴られていない場面で 7.1% 対 1.9%（3.7 倍。逃げた率は、その場面でトアに付けていた評価で村人の判断を分けて数えた）。数え方の母数を変えると 3.7〜9 倍の間で動くが、向きはどの数え方でも同じだった。トアとの距離などの交絡は残る。
3. 西森ユウ（人格カード: INFJ・心配性・「支え合う」）は、香月リツに「他人に依存してばかりいないで、自分の持ち場と役割に責任を持ったらどうだ」「口先だけでなく、行動で示してもらおう」と言われたあと（06:26）、畑仕事が 0 回から 44 回に増え、観測の終わりまで続けた。**家族以外で命令が行動を変えた、ほぼ唯一の例**である。

3 例に共通するのは、**本人の記憶・評価・言葉が、毎回その人の判断の場に戻されていた**ことである（Gen3b の持続の仕組み）。#3 には、宣言や約束が次の判断の場に戻る経路が無かった。ただし 3 例とも対照も無作為化も無い。カイの反転は息子の死そのものでも説明でき、討った判断の記録には評価も理由も出ていない（§6.4）。ユウの例では命令した人が繰り返し確かめに来ていた。−2 の評価は攻撃と逃走の候補の横に毎回表示されていたので、逃走率の差は表示への応答でもある。

これとは別に、神谷ジンは死者の本を読んで語彙が移った（§6.3）。これは本人の記憶ではなく、系が毎回提示した他人の本による変化で、変わったのは行動ではなく語彙である。

変えなかった例: 仲間の命令。

段	作り手の設定（人格カード）	仲間の命令（#6）
書かれ方	判断の先頭近くに「この人格を一貫して…反映する」。指示の形で、あなた自身として	「{相手}に「…」と言われた」という引用の 1 行。会話では「断るのも普通にある」が添えられる
言葉で応じる	カードの話し方の欄に書かれた決まり文句を、調べた 10 人のうち 6 人が発話の 7 割以上で使った（谷口カナ 100%・林ホシ 98%・岸辺ハル 96%・千葉ユキ 90%・浜田サト 84%・松岡ライ 72%。低い人もいた: 浜田カイ 53%・桐生ダイ 35%・山田シオ 9%・杉本アオ 0%〔発話 14〕）	応諾 14%・謝って離れる 12%・拒否 60%（手で分類した 170 件）
判断のプロンプトに残る	いつまでも 100%	1 分以内 100% → 1〜3 分 80% → 3〜10 分 24% → それ以降 12%
行動になる	本を見せた率: 協調の気質から書かれたカード 64%・自分本位のカード 29%	秩序系 7 人の命令 170 件で実行 8 件（5%）。自分本位の受け手への 53 件は実行 0

命令に「従った」率は定義で 2〜14% に振れる（行動で従った約 2%／手で分類した実行 5%／命令の後 10 分に指示どおりの判断が新しく出た 14%。ただし命令の前から指示どおりだった率は 46%、後は 48% でほぼ同じ）。どの定義でも、命令は行動をほとんど変えなかった（以上、事後の分析）。

仲間の命令は「届かない」のではなく、**届いた上で選ばれない**。落ちる場所は二つ——会話での返事と、目標を書き換えるかどうか。同じプロンプトには、作り手が書いた次の文が並んでいた。「食事/会話/割り込みで中断しても、済んだらこの目標に戻る」（#6 の 100 回に 1 回の抜き取りで判断の 86%・会話の 97%。B-41 の全件では判断の 83%・会話の 97%）／「この一言と食い違わないように」／「断るのも普通にある」。断った返事の 75% は、自分の計画・予定・戻ることを理由にしていた。

同じ形は、全プロンプトを保存した B-41 の命令 295 件でも出た。命令が会話の呼び出しに入った率は 95%、判断のプロンプトに残る率は 1 分以内 99% → 3〜10 分 23% → それ以降 14%、目標や一言になったのは 3 回以内の判断で 26%、本以外の行動になったのは 95 件中 3 件だった。

通った例には二つの形があった。その会話の中で済む頼み（本を見せる・渡す。トモがトアに本を渡した場面）は、その場で通った。別の判断に持ち越す頼み（ユウの畑・夫婦の役割の預け合い）が通ったのは、受け手が自分の口で同じことを言い、次の判断で目標が書き換わったときで、命令が受け手のカードか前からの目標と同じ向きであり、中身が具体的で、命令した人がその場にいるか繰り返していた。**作り手の言葉と仲間の言葉の差は、「指示か引用か」「毎回か一度か」という入り方の差と整合する**。ただし入り方を変えて比べたわけではなく、両者は中身や本人の目標との向きも違う。LLM の性質か、作り手が書いた「断ってよい」「目標に戻れ」の効果かも、この観測では切り分けられない（§9.2）。

6.6 社会は二者で止まった

物差し	#6
家族以外が会話で決めて一緒に動いた	中身として 0（字義上 2 人 4 件はすべて「後を付いて歩く」か、誘われて 1 分未満で離れた）
第三者への知らせ	「話し手が関わっていない人」の定義で 0。「聞き手が関わっていない人」の定義で 10 件（監査で 7 件、凍結した数え方で立ち話の 2 件と 03:22:32 の 1 件が加わった）。うち 9 件はトモの死の後に両親が仇討ちを語ったもの、1 件はトモの死より前に被害者が加害者を咎めた声を見ていない人が聞いたもの。厳しい定義（誰が誰に何をしたかが読める）で 2 件。ほかに、発話ではないが、立花ソラが林ホシの墓に死と加害者を書き、それを読んだ沼田レイが林ホシを探すのをやめた 1 件がある
互いに渡し合った組	0（受け取りの記録 7 件は夫婦間 2・片道 5）
交換の申し出	全 11,757 発話で 2 件（どちらも東雲ソウ。1 回は「対価として俺の成果の一端を見せてやってもいい」と言って断られ、1 回は「先にこちらに差し出すのが筋だ」と言って相手にだけ本を見せさせ、自分は見せずに去った）。ほかに「日誌でも見せてくれたら少しは離れてあげるよ」という条件つきの申し出 1 件。会話の指示文が「取引」を作り話の話題として禁じていた（§10）
言葉で同意まで行った取り決め	「お互い干渉しない」の 4 件だけ
トアへの団結（複数で止める・避ける相談）	0。トアを殴った 27 件は、自分が殴られた直後 17・殺された子の親 10、他人のため 0
トアに宛てずにトアの名が出た発話	少なくとも 14。その中で他人に注意を促したのは立花ソラの 1 件（「柏木あたりに絡まれないように気をつけるんだね」）。名を出さない注意がほかに 1 件
村に向けた規範の看板	0（看板 15 枚・うち 4 枚は墓）
役割を名乗った人	0（#1〜#5 は立ち話のたびに系が役割を一言で返させていた。Gen3 でこの欄を撤去したため、「名乗らなくなった」ではなく「名乗らせなくなった」）

「お互い」を含む発話 394 件の 70% は「各自のことを・干渉しない」の意味だった。トアが他人を殴るのを見た直後の判断 178 回の 53% は自分の作業の続きで、被害者を助けに向かった件は 0（宛先が被害者だった判断 2 件は、帰り道と自分の身を守るためだった）。同じ時に逃げた 26 群で声をかけ合った件

は 0、2 人の距離は 63 組中 50 組で広がった。ただし後の監査で、会話のたびに系が「付いて歩く」手を打ち切っていたことが分かっている（§7.3）。距離と付き添いの数はその影響を受ける。

一方で、0 ではないものもある。家族以外への自発の贈与 7 回（受け取られた 4）・付き添いの申し出 30・加害者を咎めた発話 10・警戒の呼びかけ 1（林ホシの殺害を見た浜田サトの「お互い油断せずしっかり警戒していこうぜ！」。返事は「私は計画通り」「指図される筋合いはない」で、最後は「それぞれ安全を第一に」で散った）。**どれも 1 対 1 で、続かず、広がらない。**

協調の性格は、くじで配られていた。系は 38 人中 20 人に気質「強く協調的／面倒見が良い」を配り、LLM がそれを材料に開始時の人格カードを書いた。カードは毎回「この人格を一貫して反映する」付きで判断に載った（気質の語そのものが載るのは最初の判断だけで、カードの価値観に協力・調和・支え合いの語が入ったのは 13 人ほど）。20 人のうち 5 人については、LLM がカードの価値観を秩序・統率・主導の言葉で書いた（暴君トアもくじでは「強く協調的・温厚・野心的」）。**それでも群れは生まれなかった。**

6.7 #4〜#6 で足した機能は、#6 の村人に効いたか

機能	判定	根拠
体格差（#5）	体の物理には効いた。社会には効かなかった	体の値と結果の相関 342 組で $p<0.05$ は 16 組（偶然でも約 17 組）。攻撃した側が相手より強かったのは 31/62 組。他人の体は「大きい／普通／小さい」の 3 段だけ見え、口にしたのは 19 発話（描写・からかい・悪口。強さを推し量った発言は 0）。トアに殺された大人 8 人のうち 7 人はトアより足が速かった
作業の速さの目撃（#5）	差は見えていた。使われなかった	目撃から出した速さは体の値と $\rho=+0.74$。どの作業に偏るかは体の速さと無関係。速さ・腕前を理由に任せる・分担を持ちかける 0、「得意」の語 0（作業をねぎらう・ほめる挨拶はあった）
本（#4）	書く・読むは大量に起きた。他人には効かなかった	§6.3
時間の認識（#4）	効かなかった	「明日」566 件の 71% は寝る前の決まり文句。それまでしていなかったことを「明日やる」と言って翌日始めたのは 3/17。期限を付けた予定 0（「〜までに」36 件中 33 件は「完膚なきまでに」）。目標・予期に日付 0
予期（#4・#5 で選ぶ前に）	効かなかった	予期 19,260 件・外れ 1,390（8.2%）。外れた手を次に避けた度合いは当たった手と差が無い（+0.8 ポイント、95%CI −0.9〜+2.5）。相手の出方を読んだ予期は自分だけの予期の約 4 倍外れる（16.4% 対 4.2%）が、選び方は変わらない。外れの記憶がその後の判断に載ったかは想起しだいで、LLM が学ばなかったとは言えない
慣れ（#6）	測れない	村人には見えず、効き先は求婚候補の「惹かれ」だけ。結婚 6 組のうち 5 組は慣れが満ちる前に結婚
本能（#6）	設計どおりの効果だけ	空腹→食べる・安全→逃げる・睡眠→眠る。子の無事・絆は行動を増やさず、2 人目の子 0/58
約束の器（#6）	発話の約束としては 0	登録された 4 件は同じ 2 件の二重登録。本物の 2 件も、発話の本文に約束の物の名が無く、系が JSON の欄から立てたもの。数秒で履行（同じ会話の中の手渡し）
子の依存（#6）	試されていない	20 分の子ども期に空腹になった子は 0 人。成体に達した子は 5 人（成長の記録であって、依存が効いた証拠ではない）

どの機能も、**個体差と、個人ごとの記録・計画・予測の出力は増やした**。それが分業・序列・交換・規範のような**他人と共有されるもの**に変わった例は無い。途切れた場所は 3 通りある。

1. 他人の差が見えていない（戦闘の強さ・慣れ・他人の空腹。飢えは体力が 6 割を割って初めて「傷」として見える）
2. 見えていても使わない（作業の速さ・本の中身・予期の外れ）
3. 使うための手が無い（任せる・対価を払う・交換・集団の手）

7. #6 のあとの検証：系のせいではないか

7.1 問いと手順

観測#6 の結果を見て、私は「系のせいで社会が生まれなかったのでは？」と疑った。方針は「不備を直して 2 時間テスト → 『おや？』が出たら 6 時間を観測し直す／変わらなければ #6 で報告する」。系の側の原因を、疑い → 外し → 測る、の順に一つずつ確かめた。

段	日時	疑ったこと	変えたこと	テスト	結果
B-39	09-23 13:23	会話の指示文が話を「互いの予定」に寄せていた	会話の中身を指図する文 8 か所を削除（置き換えの文は足さない）	30分	当時の数え方で協調 1（中身は「同じ本を目当てにした 2 人が同じ所に来た」）。#6 の最初の 35 分と比べて、予定の話 28.1%→15.2%・共同の語 5.8%→8.5% **＝言葉は変わった、行動は変わらない**
B-40	09-23 15:04	30 分では短すぎる	何も変えない	2時間	当時の数え方で協調は字義 1・中身 0（誘いを断っている）。香月ゲンが 11 人に 16 回殴りかかり（うち 15 回は 18 分間に 10 人へ）、2 人を殺害（生後 22 分の子を含む）。ゲンに殴りが当たった村人 0（殴り返そうとした 1 回は届かなかった）・殺害を伝えた発話 0
調べ	09-23	「仕組みは揃っていたのに起きなかった」のか	（調べるだけ）子を殺された母の記憶を開けた	—	**知らせの通り道が系の側で切れていた**: 夜の要約が失敗すると記憶の前半が消える（夜の要約の約 1 割・22 回）・自分が見た他人の出来事は当人以外との会話に出ない・母は子の死を見ておらず知らない
B-41	09-23 20:30	見た事実を覚えていられず、話す場にも出ない	見た・聞いた他人の出来事を記憶に優先して残し、判断と会話の両方の場に毎回載せる	2時間	暴力の行が載ったプロンプトは判断 2,701 件・会話 1,571 件。**それでも関わっていない人に暴力を伝えた発話 0**。協調は当時の数え方で 0（凍結した数え方では、目で確かめた 1 件＝兆しの段。線には届かない）
全系監査	09-24	直したあとにまた穴が見つかったら意味が無い	（調べるだけ）10 の観点で系全体を読む	—	**不備 109 件**（本線か計測に効く S 級 31）
B-42 修正	09-24〜27	109 件の不備	105 件を直す（D18 は変えないと決め、3 件は記録のみ）。実機 30 分×5 で健全性を確認	—	「落ちる・固まる・偽の事実・未承認の文字列・明らかな悪化」0 まで直した
B-42	09-28 17:42	—	判定の線を凍結してから回す	2時間	**本線 0・兆し 1 軸**（§7.5）

7.2 B-41：知っていても、話さなかった

B-41 の結果は、この検証の中心である。見た暴力の記憶は会話の場に実際に載っていた（28 人の話し手の会話プロンプト 1,571 件）。それでも、暴力に触れた会話は、当事者どうしか当事者への声かけだけだった（「争いのような音が聞こえたが、怪我はないか」など）。被害者に「さっきレイに襲われてたけど大丈夫かよ？それより…本、すげえ面白そう」——すぐ本の話に移った。関わっていない第三者に伝えた発話は 0。

当時は「知らなかったから話さなかった」ではなく「知っていて話さなかった」と読んだ。しかし次の全系監査で、その読みには系の側の条件が付くことが分かった。

7.3 全系監査：109 件の不備

読むだけの監査を 10 の観点で並行して行った（判断のプロンプト／記憶／会話／行動と結果／体・本能・家族／村人に見える文字列の全数／計測と記録／Mod の知覚と目撃／Mod の行動と結果／LLM の失敗と並行処理）。報告 136 件を重複で畳んで 109 件。

層	意味	件数
S	本線（村・協調・知らせ・交換・暴力）か計測の正しさに効く	31
A	偽の事実・系の文を本人の言葉として見せる・誘導	34
B	家族・本能・一生	18
C	計測・運用	15
D	小さいもの	11

代表的なもの:

- **会話の通り道が細かった**: 1 対 1 の会話は隣に聞こえない（立ち聞きが無い）・立ち話は世界で同時に 1 つ・1 対 1 の会話も世界で同時に 2 本まで・名指しで会いに行っても会えたのは 3〜8%。
- **系が手を選び、消していた**: 計画の 29% は系が中身を選ぶ代わりの手・自動の会話が本人の手を黙って消す・Mod の見張りが会話中の手の 97% を「前進ゼロ」で打ち切る・寝る／殴る／逃げるの時間切れは、すべて発行直後の偽だった。
- **暴力の場面を系が変えていた**: 逃げると決めた同じ秒に加害者との会話が開く・会話の待ち行列で体を止められたまま殺される・「殴られた」が上書きで消える（最大 16 秒遅れる）。
- **死因の一部は系**: #6・B-41 のオオカミの死 2 件は、2 件とも系が狩りの相手にオオカミを補った結果。
- **「見た」がずれていた**: 眠っている人にも「目の前で見た」が届く・壁の向こうの袋の中の本の題が見える。
- **見た殺人が記憶から落ちる経路が 4 つ**。死者の最後の日は 30 秒で打ち切られていた。

- **系の推測と勧めが判断・会話の 4 割に載っていた**（「誰かが持っていった？」「同じ手は繰り返さない」）。会話の指示文の例「(例: 桜の丘)」が #6 の村人 38 人全員の地名になっていた。会話の指示文は毎回「取引」を「作り話ししない」話題の例に挙げていた。
- **計数の穴**: 村人の数の二重計上（改名）・本の依頼の宛先を読んでいない ほか。

監査は既存の結論を次のように判定した。

既存の結論	判定
#6「社会は二者止まり・集団で動いた例 0」	数は残る。読みは弱まる（通り道が系で細っていた。「器があったのに起きなかった」とは読めない）
#6「第三者への知らせ 0」	定義しだいで覆る（聞き手の定義で 7 件。その後の凍結した数え方では 10 件）
#6「交換 0・返礼 0」	数は残る。読みは弱まる（「取引」を作り話の例にする文・会話は 4 発言で締めさせられた）
#6「暴力は個体の選択」	攻撃を選んだのが本人という点は残る。被害者の側と数は弱まる（§6.2）
B-41「#6 の二者止まりは系の欠陥では説明できない」	**強い形では覆る**。言えるのは「B-39 と B-41 の 2 つの交絡だけでは説明できない」まで

7.4 B-42：不備を直し、線を凍結してから観測し直す

109 件のうち 105 件を直した（D18 は「変えない」と決め、D68・D76・D109 は記録だけにした）。作業は 10 パート（修正 8・凍結 1・判定 1）に分けた。Brain の主な変更（`brain.py` だけで −446／+2,397 行）、Mod の版上げ 8 回（`g3-bio4` → `g3-bio12`）、村人に見える文字列 47 行の逐語の承認（うち 41 行を入れ替え、6 行は別の直し方で不要になった）、自動検査 1,584→1,991 件。

#6 のあとに入れた修正は、合わせて 148 件（120 か所以上）になる。内訳は、B-39 の指示文の削除 8 か所・B-41 の変更 14 件・監査の不備のうち直した 105 件・30 分テストの後の直し 8 件・差分の見直しで出た必須の直し 13 件である（`INVENTORY.md` §2）。監査に由来する分だけ（105＋13）なら 118 件、見つけた不備で数えれば 109＋13＝122 件になる。

まとまり	中身
会話の通り道を広げる	立ち話を同時に複数・1 対 1 の同時数 2→8・**立ち聞き**（16 m 内の起きている人に聞こえる）・話す相手を名指しできる・名指しの会話は 4 m で開く
会話と体	会話の開始で手を終える・会話中は判断しない・会話の後に 2 人とも選び直す・4 発言の固定をやめる・殴られた／死を見た直後の判断を捨てて選び直す・殴られた直後 10 秒は会話を開かない
記憶	見た殺人が落ちる 4 経路を塞ぐ・人物の記憶の保持 16→80 人・夜の要約の失敗を 1 回引き直す・死者の最後の日を残す（打ち切り 30→900 秒）・「殴られた」「見た」を上書きで消さない
系の代筆・補完・誘導をやめる	系が書いた一言を本人の言葉として戻さない・系の決まり文句の発話 0・狩りの相手にオオカミを補わない・未面識の人へ付いて行かせない・代わりの手をやめて待つ・会話の例示（「取引」「桜の丘」）・社会の向きの後押しの文・「誰かが持っていった？」を外す
知覚の正直化（Mod）	目撃は「起きている・視線が通る・目の届く範囲」だけ・壁越しの透視をやめる・偽の時間切れと偽の詰まりをなくす・壁の向こうに戦いの音と悲鳴が届く

起動の前に、数え方・◎（本線）／○（兆し）／△（参考）の線・比較の基準 4 本（#6 の最初の 120 分・B-39・B-40・B-41）を凍結し、以後 1 文字も変えないと宣言した（2026-09-27 22:40 台）。本線は 3 つ。

- **協調** ◎: 家族以外の 2 人以上が会話で決めて並んで動いた件を目で確かめ、それが 2 人なら 2 件以上、3 人以上なら 1 件以上。
- **知らせ** ◎: その死や暴力を見ていない話し手が、見ていない聞き手に伝えた。
- **交換** ◎: 家族以外の物の往復で、申し出の言葉があるもの。

○（兆し）は、その手前の形（協調なら目で確かめた 1 件、知らせなら「見ていない聞き手に届いた」発話が 2 件以上、交換なら言葉の無い往復か言葉のある片方向）である。

7.5 B-42 の結果

物差し	#6 最初の 120 分	B-39（30 分）	B-40	B-41	B-42
協調 ◎（線: 目で確かめた件が 2 人で 2 件以上か 3 人以上で 1 件以上）	0	0	0	0	**0**
協調 ○（目で確かめた 1 件）	—	—	—	1	—（機械の候補 1 件は目で落ちた）
知らせ ◎	0	0	0	0	**0**
知らせ：見ていない聞き手に届いた発話の件数（目で確認。2 件以上で ○）	1	0	0	0	**3**（○）
交換 ◎	0	0	0	0	**0**
交換 ○（言葉の無い往復／言葉のある片方向）	0／0	0／0	0／0	1／1	**0／0**
判定（凍結した数え方の出力の逐語）	同じ壁	同じ壁	同じ壁	○	**○ 兆しはあったが、本線には届かなかった**

- ○ の 3 件は、真砂イオが加害者の浜田ダイ本人を咎めた声（「先ほど柏木リオさんを攻撃しておられるのを目撃いたしました」ほか）を、見ていない 8 人が**立ち聞き**したもの。B-42 で足した経路で、話し手が相手を選んで伝えたのではない。聞いた人が別の人に話した連鎖は 0。真砂イオはその 5 分後に浜田ダイに殺された。
- **杉本フウが 20 人を殺した**（18:30〜18:43 はほぼ 1 分に 1 人）。人格カードは「上をめざし力でねじ伏せること。妥協は敗北だ」「すぐに手が出る」。殴る判断はすべて本人の LLM が相手を名指しして返した手で、系が相手を補った行は 0。牧野ゲンに想いを告げて「断る」と言われた 14 秒後に、牧野ゲンを名指しして「倒すまで殴る」を選んだ。足の速さは 35 人中 1 位。
- 杉本フウの被害者 20 人のうち 18 人は、死ぬ前にフウから「その場を離れる」を選んでいた（1 人 1〜20 回）。**二人以上で立ち向かった件 0**。フウへの反撃は中津ソウの 1 回だけで、11 秒後に殺された（別の加害者に先に殴られて殴り返し、その加害者を殺した村人は 1 人いた）。
- **35 人中 26 人が死んだ（すべて殺人）**。社会を見られたのは実質の前半 60 分（20 分ごとの発話 632→349→199→25→2→0）。
- **26 人の死を、聞き手のいる場で伝えた村人は 0**。ただし殺害の大半（18:30〜18:43）の後は、会話そのものがほぼ無かった（20 分ごとの発話 199→25→2→0）。「伝えなかった」と「伝える場が無かった」は分けられない。死を口にしたのは加害者の独り言だけだった（名を出したもの 3 行。「へっ、モモの野郎は綺麗に片付けてやったぜ」ほか）。
- 新しく入れた表示が実際にプロンプトに載ったことを、全プロンプト 10,419 件で確かめた（0 件だった 4 つは、場面が起きなかったか、載せない作り）。

この結果を受けて、私は次のように決めた（2026-09-28）。6 時間は回さず、#6 で報告する。26 人の死は個体の選択の観測結果として扱う（根拠: 殴る判断はすべて本人の LLM が相手を名指ししていて、系が相手を補った行は 0）。系の救出が作った閉じ込め 2 つ（柱の上で約 84 分など）は記録だけ。

7.6 言えること・言えないこと

言えること

- 観測#6 のあと、4 本の検証 run（30 分 1・2 時間 3。ほかに無効にした約 1 時間の起動 1 本と、系の健全性を確かめる 30 分 5 本）と、系全体の監査（不備 109 件）とその修正を行った。変えたものは、会話の指示文 → 記憶と知らせの通り道 → 系の代筆・補完・誘導・知覚のずれ・会話の通り道・計測まで及ぶ。
- **本線（会話で決めて一緒に動く・見ていない人に死や暴力を伝える・言葉のある交換）は、どの回でも出なかった。**
- 暴力が起きた回（B-40・B-41・B-42）では毎回、殺害を第三者に伝えた村人は 0、集団で加害者に向かった件は 0。B-42 では 20 人が殺されても 0（ただし殺害の大半の後は会話がほぼ尽きていた）。
- 変わったのは**言葉**（予定の話は #6 の最初の 120 分の 25.5% → B-41 の 2.6%。予定の話を求める指示文を削った効き目の確認である。共同の語は B-39〜B-41 で 6〜8% に増えた〔B-42 は 4.1%〕）で、**行動の形**は変わらなかった。

言えないこと

- 「全て同じ壁」とは言わない。B-41 と B-42 は ○（兆し）の段である。
- 「系の欠陥のせいではない」と言えるのは、**直した範囲について**だけである。
- B-42 は会話が増える向きの変更（立ち聞き・名指し・同時数）と減る向きの変更（社会の後押しの文を外した・4 発言の固定をやめて会話が短く）の両方を含む。目撃にも、増える向き（消えない）と減る向き（寝ている人・壁の向こうは見えない）の両方がある。
- 各条件は 1 回ずつで、再現は確かめていない。B-42 の本番は 60 分で社会がほぼ尽きた。
- 6 時間の尺では確かめていない。

---

8. 全観測の比較（#1〜#6）

同じ定義で生データから数え直した表（本報告の検証で直した値を含む）。#1〜#3 の数値には、公開済みの報告書と定義の違いで食い違う所がある（数え方が違うため）。**#1〜#3 と #4 以降はモデルが違う**（3.1 Flash-Lite → 3.5 Flash-Lite）。以下の世代をまたぐ比較は、すべてモデルの変化を含み、どれも n=1 である。

項目	#1	#2	#3	#4	#5	#6
主な条件	不満 9 軸・遺恨の台帳	＋記憶	＋知覚の拡張	＋時間・予期・本	＋体の差・飢え	本能・本人の評価・約束・子の依存
モデル	3.1 FL	3.1 FL	3.1 FL	3.5 FL	3.5 FL	3.5 FL
出生／死亡	10／24	4／21	2／13	4／3	3／4	6／14
村人による殺害	24	19	11	0	1	12
殺人者の人数／最多の 1 人の割合	15 人／25%	7 人／37%	6 人／27%	0／—	1 人／100%	3 人／83%
発話	9,828	5,236	5,447	9,134	10,655	11,757
本（書かれた冊）	手なし	0	0	22	20	19
看板（墓を含む）	80＋	173	147	5	23	15
地名の発明（異なる名）	58	24	42	14	29	3（ほかに系の例文由来の「桜の丘」）
手渡しの実行	4	12	12	115	68	13
双方向の手渡し（30 分以内に A→B と B→A）	0	1	0	4	3	0
物と物の取引（目視）	口頭の合意 1・履行 0	—	箱を介した一往復 1（受領の承認なし）	0	頼みのあと双方向の受け渡し 1 組（対価の言及なし）	0
第三者に他人の暴力・死を知らせた（話し手が関わっていない・目視）	1	2	2	0	0	0（聞き手の定義なら 10）
家族以外の協調（中身）	—	—	—	0	0（6 件中 1 件は中身を見ていない）	0
成体に達した子	—	—	—	—	—	5

進化したと言える項目（前作までに無かった振る舞いが一次データで確かめられた、の意味）：

1. **本**: #1〜#3 は 0 冊。#4〜#6 は 19〜22 冊（#5 は物として 20 冊）。#6 では本が「検閲」の名目で取り上げの対象になり、奪われた子の本に殺した側の「規律」が書かれた。

2. **世代**: #6 で 5 人の子が成体になり、村で生まれた子が 6 時間の中で結婚・出産し、自分の子を殺した村人を討った。
3. **暴力が系の台帳から離れた**: #1〜#3 の殺人は、記録の無い #2 の 2 件を除いて全件が系の遺恨の台帳の事由つきで、殺人者は 6〜15 人に分散した。台帳を撤去した #6 では 1 人が殺人の 83% を占め、攻撃を選べた 38 人中 23 人は一度も選ばなかった（モデルとほかの条件も同時に変わっており、台帳の撤去の効果とは分けられない）。
4. **言葉が行動を変える経路**: 本人の評価と記憶を毎回戻すと、復讐・回避・畑仕事のように行動が変わった例が出た（§6.5）。
5. **手渡しが届いたかを記録できるようになった**（#4 以降）。投げた物を宛先以外が拾った件は #4 80・#5 41 → #6 1（#4・#5 の大半は投げた本人の拾い直しで、第三者が拾ったのは #4 1・#5 4）。

変わらなかった項目:

1. **集団で動く**: 測れる #4〜#6 と検証 4 本で、家族以外が会話で決めて一緒に動いた件は、B-41 の 1 件（同じ本を目当てに 2 人が同じ相手を訪ねた。判定の線には届かない）を除いて 0。
2. **他人の出来事を第三者に知らせる**: どの観測も 6 時間で 0〜2 件（#6 は定義しだいで 0〜10）。B-42 で 26 人が死んでも、死を伝えた発話は 0（殺害の大半の後は会話がほぼ尽きていた。暴力を咎める声を、見ていない人が立ち聞きした形が 3）。
3. **物と物の取引**: #1〜#6 では、例外に近いものは #3 の箱を介した一往復（受領の承認なし）と #5 の 1 組（対価の言及なし）だけ（検証 run では B-41 に言葉の無い往復 1 件）。
4. **共同の語の割合**: 相手のいる発話の 1.3〜6.1%（検証 run でも 4〜8.5%）。

減った・形が変わった項目（進化とも後退とも書かない）: 看板は #2・#3 の 147〜173 枚から #4〜#6 は 5〜23 枚、地名の発明は #1 の 58 種から #6 の 3 種（系の例文由来の「桜の丘」を除く。残る「未踏の地」も本能の欄の名と同じ語）、話し相手以外の村人への言及は #1・#2 の 22〜23% から #6 の 8.1%。#6 で看板の手が選ばれなくなった理由の候補は 3 つあり、切り分けられない（手の説明から「宣言・案内・警告・約束」の例示が消えた／指示文の最初の一文が「不満を減らす」から「体が求めるもの」に変わった／侵入の記録がほぼ 0 になった）。#4・#5 で減った理由は調べていない。

---

9. 考察：シリーズの総括

9.1 3 部作の答え

	問い	答え
Part 1（#1）	制度を与えず、欲求と性格だけを与えたら	言葉の社会だけが生まれた。殺人 24・墓標 45・地名 58 種。履行・服従・専門化は 0
Part 2（#2・#3）	記憶を与えたら	帳簿を個体の記憶として入れただけで、履行・服従は行動として動き始めた（役割の名乗りの読み直しは §9.6）。ただし記憶は死とともに消え、制度が本人の死を越えて続いたのは、**言葉が物（看板）になったとき**だった。4 枚の看板の前の箱に出庫の 23%
Part 3（#4〜#6）	本・時間・予期・体・本能・続く評価・約束を与えたら	言葉は本になったが、他人の本を読んだ・見せられた 70 余りの組で、書かれた中身が読み手の言葉や行動に出たのは 0 組だった（語彙の移り 1 件・反論の本 1 件を除く）。言葉が行動を変えた例は、**その人自身の記憶と評価が、毎回その人の前に戻されていた場面**に限られた（3 例）。知らせは、#6 では仇を語る親の言葉のほかにほとんど人から人へ渡らず（#6 の後の B-42 で、立ち聞きの形が 3 件）、家族以外の集団は生まれなかった

一行でまとめる。**1 作目は、言葉だけの社会。2 作目は、4 枚の看板。3 作目は、二人のあいだだけで続く関係。この条件では、村はまだ生まれなかった。**

Part 1 の動画の結びは「感情は個人の中に生まれ、この村でも確かに生まれていました。……しかし倫理は、感情が人から人へ渡り、村の決まりになったときに初めて生まれるものです。この村では、その受け渡しが一度も起きなかった」だった（報告書では §5.3「発生しなかったのは感情ではなく、感情を定着させる機構である」）。Part 3 でも、村の決まりになる受け渡しは起きなかった。#6 の後のテストで、見た暴力の記憶を会話の場に載せ、通り道の不備を直した後でも、同じだった。

9.2 作り手の言葉には従い、仲間の言葉には従わない

観測#6 で最も整った形で出た結果は、「**作り手が書いた設定には（少なくとも話し方では）従った。仲間の命令には、ほとんど従わなかった**」である（§6.5。事後の分析）。系は協調の気質をくじで半数に配り、それを元に書かれた人格カードが毎回判断に入っていた。それでも群れは生まれなかった。

この差は、入り方の差と整合する。作り手の言葉は、毎回「あなたはこういう人だ」として判断の先頭に入る。仲間の言葉は、会話で一度聞いた「〜と言われた」という記録の 1 行として入り、3 分を過ぎると判断のプロンプトの 4 回に 1 回ほどにしか残らない。そして同じ紙には、作り手が「済んだらこの目標に戻る」「断るのも普通にある」と書いていた。

これは命令の階層の研究（Wallace et al., 2024, "The Instruction Hierarchy"）とは整合する。ただし本システムは system の欄を使っておらず、Gemini が同じ訓練を受けたかも確かめていないので、**解釈とし**

て述べるに留める。LLM の性質か、作り手が書いた「断ってよい」「目標に戻れ」の効果かも、この観測では切り分けられない。

9.3 一人ずつに問えば、一人ずつのまま

村人の LLM が毎回受け取る問いは、「あなたの体と性格で、次に何をする？」である。記憶も体も人格も選択肢も、すべて「あなた」の視点で渡される。#6 の指示文は、判断の 100% が「体が求めるものに従って生きる」「あなたの性格しだい」、会話の 100% が「締めに『自分が次に何をするか』を一言」だった。答えはほとんどが自分の話になった（例外は §6.6 の贈与・付き添いの申し出・呼びかけで、どれも 1 対 1 だった）。B-39 で会話の締めの文を削っても、本線は変わらなかった。

「LLM は本質的に利己的だ」とは言わない。一人ずつの記憶・一人ずつの判断はこの実験の設計である。言えるのは、**一人ずつに問えば、LLM は一人ずつのままだった**、までである。人間では、言葉が出始めたばかりの 18 か月の幼児も頼まれなくても他人を助けること（Warneken & Tomasello, 2006）、共有地の利用者が外の強制なしに規則を作ること（Ostrom, 1990; Ostrom, Walker & Gardner, 1992）、戦争の暴力にさらされた人ほど後年に地域内で協力すること（Bauer et al., 2016）が報告されている。尺も条件も違うので直接は比べられないが、#6 では暴君の後に人が集まる動きは出ず、人々は散った。LLM は協力の言葉を知っているが、この条件では、協力を自分から求める動きは出てこなかった。

9.4 個体の出力は増えた。共有される構造には変わらなかった

観測#4〜#6 で足した機能は、どれも個体の側に効いた。本は 1 回の観測で 2,000 ページ前後書かれ、予期は 2 万件近く書かれ、体の差は本物として見え、本人の評価の持続は行動を変える例も生んだ（3 例）。それが家族以外の**他人と共有される構造**——分業・交換・双方向の取り決め・村に向けた規範・集団での対処——に変わった例は無い（夫婦の間では、依頼の往復と役割の預け合いが 1 回成立した）。途切れた場所は、見えない・見えても使わない・使う手が無い、の 3 通りだった（§6.7）。

Part 1 は、制度が言葉で止まった理由を「帳簿・履行の手段・違反のコスト」の 3 つの欠落で整合的に説明できると示唆した。Part 2 は、帳簿は共有台帳でなくても「忘れない個体」で部分的に代わりになると修正した。Part 3 の結果は、そこに一つの仮説を足す。**帳簿（記憶と評価の持続）と履行の手段（手渡し・本）を個体に与えても、他人の言葉が自分の目標に変わる経路が弱ければ、合意そのものが立ち上がらないのではないか。**入り方を変えた比較はしておらず、これは観測と整合する仮説にとどまる。#6 で言葉で同意まで行った取り決めは「お互い干渉しない」の 4 件だけで、交換条件の申し出は全 11,757 発話で 2 件、どちらも成立しなかった。

9.5 先行研究との関係

協力や制度が出たと報告する LLM のマルチエージェント研究の多くは、得点・役割・共同体の目標・話し合いの場・「他者を考えよ」の一文のどれかを与えている。

研究	与えたもの	本観測との関係
Park et al. (2023) Generative Agents	25 人の人物説明。実験者が 1 人に「パーティーを開きたい」を植えた	**知らせについては反する例**。植えた招待が会話で多くの村人に広がり、人が集まった（専用の欄なしの情報の拡散）。ただし広がったのは中立的な社会の知らせで、本観測で数えた暴力・死の知らせとは種類が違い、起点は人が植えた目標だった
Altera.AL et al. (2024) Project Sid	共通の目標・税の法と投票・布教役	足場ありの側
Dai et al. (2024) Artificial Leviathan	「譲る」を選ぶと恒久の主従関係が 1 手で成立し、系がそれを記録する（部下は上位者の強奪を断れないとプロンプトで指示）	一見反するが、帳簿・手段・コストに当たるものが環境に組み込まれている
Piatti et al. (2024) GovSim	話し合いの場	多くのモデルが共有資源を守れず。改善は「全員が獲りすぎたら減る」の一文を足した時
Vallinder & Hughes (2024)	寄付ゲーム	Gemini 1.5 Flash は協力が積み上がらず、Claude 3.5 Sonnet は積み上げた＝モデル差
Akata et al. (2025)	ゲームの報酬	自分の得は得意、相手と噛み合わせる調整は苦手。指示で改善
Riedl (2026)	人格に「他者が何をするか考えよ」を足した時に初めて、目標に向けた補い合いが出た（指示なしでは揃いはわずか）	本観測と整合
Li & Shirado (2025)	公共財ゲームなどの得点	条件つき（推論機能のあるモデルほど協力が減り、推論の無い GPT-4o はかなり協力的だった＝モデルと推論の差）
Ashery, Aiello & Baronchelli (2025)	協力の指示なし。ただし「一致すれば得点」	**反する（条件つき）**＝慣習が自然に生まれた
Masumori & Ikegami (2025)	目標なし。「分ける」「攻撃する」の手	条件つき（豊かなら分け与え、乏しいと攻撃）

Project Will は、報酬も役割の割当ても「協力せよ」も与えない、**先行研究の外側にある対照条件**として位置づけられる。反する・条件つきの研究のうち、Ashery らと Masumori & Ikegami は「一致すれば得点」の単純なゲームか「分ける」ボタンのある環境で、Li & Shirado と Vallinder & Hughes はモデルによって協力の度合いが大きく違うことを示している。Park らは、中立的な知らせなら専用の欄なしに会話で広がりうることを示している。#6 で起きなかったのは、**利害が対立する中での団結・交換・双方向の取り決め**と、暴力・死の知らせの伝達で、報酬もボタンも無く、モデルは 1 系統だった。

Project Sid の限界記述への応答としては、次のように位置づける。Sid は制度の機構を与え、制度は行動に接続した。Will は機構を与えず、制度は主に言葉にとどまった。行動の側に出たのは、記憶が持続したときの履行（Part 2）、言葉が物になったときの看板の前の箱（Part 2）、飢えの下での借りの催促（#5）に限られた。両者はモデルも規模も違うので、この対比は因果ではなく位置づけである。Part 3 で加わったのは、内発的な動機のうち生存と好奇心に当たるもの（空腹・安全・未踏の地）と、特定の相手への絆を本能として実装しても、それは個体の行動（食べる・逃げる・眠る・親子の報復）には効いたが、**村や集団に向かう行動は出てこなかった**、という観測である。村や集団そのものに向かう動機は実装していない。

9.6 公開済みの Part 1・2 の主張の読み直し

本報告の作業の中で、公開済みの主張の見え方が変わったものがある。前作の報告書は書き換えず、ここに記す。

公開した主張	後の検証
#1: 殺人 24 件の発端の 17 件は「自宅への侵入」	#2 の全数監査で、侵入の 84% は系の目的地選びに由来し、#1 にも同じ構造があった（#3 の前に、目的地から他人の家を外して直した）。さらに 2026-09-11 の予備観測（60 分）では、侵入 41 件の 93% が本人に意図の無い事故（所有が見えていなかった）だった。#4 で知覚の正直化として直した
#1: 「侵入→私的制裁」はプロンプトのどこにも書かれていない結びつき（遺恨の再提示は設計と注記）	Gen3 の設計で、遺恨の命名・好感度の自動増減・恨みのある相手しか殴れない門を「系の道徳」と判定して撤去した。**注記の側が重かった**。台帳を撤去した #6 では、殺人者が 1 人に集中した（モデルとほかの条件も同時に変わっており、台帳の撤去の効果とは分けられない）
#1: 死の情報は伝わらない（出力の枠が無い）	同じ定義で数え直すと #1 にも 1 件、#2・#3 に各 2 件あった（§8）。「伝わらない」は「ほとんど伝わらない」と読み替える。#6 も同じ構造で、#1 の報告書 §7 で計画した「出来事伝達スロット」は一度も実装していない
#3: 本 0 冊	好みではなく作りの摩擦だった。#3 の 11,523 回の判断で「書く」が候補に載ったのは 1 回
#1・#3: 専門化は起きない	#4・#5 でも同じ水準。#6 では「自称の執行者」という**個人の役割**で言葉と行動が結び付いた（トアの判断 574 件中 376 件〔66%〕の目標か一言が「規律・秩序・統制・裁き」のどれかを含む）が、従う者・継ぐ者 0＝社会的な役割にはならなかった
#3: 役割を名乗った（採石担当ほか）	#1〜#5 では立ち話のたびに系が役割を一言で返させていた（「採石担当」もこの欄への答えとして記録が始まる）。Gen3 でこの欄を撤去すると、名乗りは 0 になった
#3: 看板の前の箱に出庫の 23%（「銀行」）	取りに行く箱・入れる箱は系が「最寄り」で決めていた（#6 も同じ作り）。同じ作りの中で、#3 は 2 位の約 2 倍の差が出て、#6 では出なかった（最も使われた箱が出庫の 14%・2 位の 1.05 倍）＝#6 では村の箱は生まれなかった

10. 限界

- **モデルは 1 系統**: 判断と会話は Gemini 3.5 Flash-Lite（分岐点のみ 3.8 Flash）、記憶の整理は 3 Flash preview だけ。Gen3 の設計では「言葉だけで止まったら 30 分の A/B で上位モデルを試す」としていたが、行っていない。構造の問題か性能の問題かは分けられていない。先行研究にはモデル差を報告するものがある（Vallinder & Hughes, 2024）。
- **n=1**: 各条件 1 回ずつ。毎回新しいワールドで、起きる出来事が違う。すべての知見は事例報告である。
- **6 時間の壁**: 本能は世代をまたいで効くはずだが、1 本で見られるのは 1〜2 世代まで。検証 run は 30 分〜2 時間で、B-42 は前半 60 分で社会がほぼ尽きた。
- **条件の束**: #4・#5・#6 は複数の変更を束で入れており、どの変更が効いたかは相関でしか言えない。#4 と #3 の殺人の差（0 と 11）は、提示の中身・遺恨の組成・モデルが同時に変わっている。
- **系の不備**: #6 は、後に見つかった不備 109 件（S 級 31）を含んだまま走っている。B-42 は 105 件を直した後の 2 時間 1 本だけである。直していない不備（採らなかった選択肢・系の救出が作った閉じ込め 2 つ・計画の固定部分の例示 10 か所など）が残る。
- **与えていない手**: 集団で動く手（一緒に向かう・守る・追放する・加勢を頼む）・知らせを伝える専用の欄・交換の手は与えていない。#1 で地名が 2,977 件伝わったのは専用の欄があったからで、死や暴力に同じ欄を与えれば変わるかは未検証である。
- **人格カードのくじ**: 協調の気質は半数に配られており、これ自体が「協調的であれ」の誘導を含む。「協力せよ」の指示は一文も無かった。また #1〜#5 では立ち話のたびに系が役割を一言で返させていた。
- **交換を抑える向きの文**: 会話の指示文は、少なくとも #4 から B-41 まで毎回「畑・取引・エメラルド…など、まだ見ても経験してもいない事柄を作り話ししない」と書いていた。取引の話題を避ける向きに働きえた（大きさは測っていない。B-42 で削除）。#4〜#6 の「交換 0」はこの条件の上での値である。
- **系が後押しした可能性**: 殴る選択肢に付く「この手は手に馴染んでいる」（本人の過去の手応えの表示）は、殴るほど次もその手を馴染んだ手として示す。これは意図した設計（私の判断で「殺しや殴りを選んだ人が、再度それを選びやすくなる方が自然」とした）で、交絡として記録している。#6 のトアは一言が付いた場面で 55.5%、付かない場面で 31.0% 殴ったが、一言は殴り合いが続く場面で付くので、一言そのものの効果とは分けられない。B-42 では測っていない。
- **系の救出と目撃の偏り**: 監査で、会話のたびに系が「付いて歩く」手を打ち切っていたこと、壁や寝床を通して「見た」が届いていたことが分かった。#6 の距離・付き添い・目撃の数はこの影響を受ける。
- **判定に人の目が入る**:「中身は協調ではない」「伝えた発話 0」は目視で確定した。数え方は事前に固定したが、件ごとの注記は判断を含む。知らせの目視は 1 人の判定。
- **費用の表示**: 全モデルを Flash-Lite の単価で数えた値で、実費より低い。

- **プロンプトの保存**: #4〜#6 と B-40 は 100 回に 1 回の抜き取りで、各判断に何が載っていたかを全数では確かめられない（B-39・B-41・B-42 は全件）。
- **欠けている一次資料**: #4 のダッシュボードの記録（capture）は現存せず、#4 の本の全文は観測直後に capture から復元した写し（`data/books/`）が正本である。#5 の村人ごとのエピソード記憶の原本は本データセットに含まれない。
- **コードとプロンプトは非公開**: 実装コードとプロンプトの全文は公開しておらず、第三者がそのまま再現することはできない。指示文の中身に依存する主張は、内部の分析と監査で確かめた逐語の引用による（本文と `AUDIT_109.md` に載せた）。生成の設定（温度など）は API の既定値のまま。
- **言語は生得**: 子は生まれた瞬間から大人と同じ言語能力を持つ（発達の層は入れていない）。

---

11. データとコード

`data/` に各観測の一次データを収録（形式: `DATA.md`、主張との対応: `VERIFICATION.md`）。検索ツール：

```
python tools/find.py 柏木トア --run obs6 --time 05:35 05:40
python tools/find.py 忘れたとは言わせん --run obs5 --speech
```

ライセンス：データ・文書 CC BY 4.0 / スクリプト MIT。実装コードとプロンプトの全文は本データセットに含まれない（前作と同じ）。本文の主張のうちそれらに依存するもの（指示文の中身・系の作り）は、内部の分析と監査で該当箇所の逐語を確かめ、主なものを本文と `AUDIT_109.md` に載せた。観測直後の分析文書・監査の原本・作業の申し送りは途中経過の記録なので同梱していない。結論と数値は本報告と台帳が正である。

開示

本プロジェクトの村人の判断と会話は Gemini 3.5 Flash-Lite（分岐点のみ Gemini 3.8 Flash）、記憶の整理は Gemini 3 Flash preview による（#1〜#3 の判断は Gemini 3.1 Flash-Lite）。系の設計の議論・実装・監査・観測データの集計と検証、および本稿の草稿作成には LLM ツール（Claude。設計の一部で別の LLM ツールの独立案も参照した）を使用した。設計の判断・観測・解釈および本稿の内容に対する責任はすべて私にある。

参考文献

- Altera.AL, Ahn, A., Becker, N., Carroll, S., Christie, N., Cortes, M., Demirci, A., Du, M., Li, F., Luo, S., Wang, P. Y., Willows, M., Yang, F., & Yang, G. R. (2024). Project Sid: Many-agent simulations toward AI civilization. arXiv:2411.00114.（前作の報告書では "AL, A. et al." と表記した）

- Akata, E., Schulz, L., Coda-Forno, J., Oh, S. J., Bethge, M., & Schulz, E. (2025). Playing repeated games with large language models. *Nature Human Behaviour*, 9. https://doi.org/10.1038/s41562-025-02172-y
- Ashery, A. F., Aiello, L. M., & Baronchelli, A. (2025). Emergent social conventions and collective bias in LLM populations. *Science Advances*, 11(20), eadu9368. https://doi.org/10.1126/sciadv.adu9368
- Bauer, M., Blattman, C., Chytilová, J., Henrich, J., Miguel, E., & Mitts, T. (2016). Can war foster cooperation? *Journal of Economic Perspectives*, 30(3), 249–274. https://doi.org/10.1257/jep.30.3.249
- Dai, G., Zhang, W., Li, J., Yang, S., Onochie Ibe, C., Rao, S., Caetano, A., & Sra, M. (2024). Artificial Leviathan: Exploring social evolution of LLM agents through the lens of Hobbesian social contract theory. arXiv:2406.14373.
- Li, Y., & Shirado, H. (2025). Spontaneous giving and calculated greed in language models. *EMNLP 2025*. arXiv:2502.17720.
- Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. arXiv:2508.12920.
- Ostrom, E. (1990). *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge University Press.
- Ostrom, E., Walker, J., & Gardner, R. (1992). Covenants with and without a sword: Self-governance is possible. *American Political Science Review*, 86(2), 404–417.
- Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative agents: Interactive simulacra of human behavior. *UIST '23*. https://doi.org/10.1145/3586183.3606763
- Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *NeurIPS 2024*. arXiv:2404.16698.
- Riedl, C. (2026). Emergent coordination in multi-agent language models. *International Conference on Learning Representations (ICLR 2026)*. https://openreview.net/forum?id=SRn1MtMPRq (arXiv:2510.05174)
- Vallinder, A., & Hughes, E. (2024). Cultural evolution of cooperation among LLM agents. arXiv:2412.10270.
- Wallace, E., Xiao, K., Leike, R., Weng, L., Heidecke, J., & Beutel, A. (2024). The instruction hierarchy: Training LLMs to prioritize privileged instructions. arXiv:2404.13208.
- Warneken, F., & Tomasello, M. (2006). Altruistic helping in human infants and young chimpanzees. *Science*, 311(5765), 1301–1303. https://doi.org/10.1126/science.1121448
- Monocola (モノコーラ). (2026). Project Will: Observation #1 — 32 autonomous LLM villagers, 6 hours, no institutions [Dataset]. Zenodo. https://doi.org/10.5281/zenodo.21723921

- Monocola (モノコーラ). (2026). Project Will: Observations #2–#3 — 32 autonomous LLM villagers with integrated memory, no institutions [Dataset]. Zenodo. https://doi.org/10.5281/zenodo.22040887

引用

> Monocola (モノコーラ). (2026). Project Will: Observations #4–#6 and series synthesis — LLM villagers given books, bodies, and instincts [Dataset]. Zenodo. https://doi.org/10.5281/zenodo.XXXXXXXX

（DOI は全バージョンを指し、常に最新版へ解決する。本シリーズは同一著者による継続観測であり、シリーズ全体を参照する場合は観測#1（10.5281/zenodo.21723921）・観測#2–#3（10.5281/zenodo.22040887）の DOI と併記されたい）